Laporan Studi Literatur dan Eksplorasi Dataset

Computer Vision, Convolutional Neural Network (CNN), dan Object Recognition
Tugas Personal 1 — Week 2, Sesi 4 — Penelitian Awal

1. Pendahuluan

Computer Vision (CV) adalah bidang ilmu komputer yang mempelajari bagaimana komputer dapat memahami dan menginterpretasikan informasi visual dari gambar atau video, layaknya kemampuan visual manusia. Proses ini melibatkan Image Processing sebagai tahap awal — mengolah piksel mentah agar lebih mudah dianalisis (misalnya normalisasi, resizing, atau augmentasi) — sebelum masuk ke tahap pengenalan pola yang lebih kompleks seperti klasifikasi objek, deteksi objek, dan segmentasi gambar.

Convolutional Neural Network (CNN) menjadi arsitektur dominan dalam CV modern karena mampu mempelajari fitur visual (tepi, tekstur, bentuk, hingga objek utuh) secara otomatis langsung dari data gambar, tanpa perlu perekayasaan fitur manual seperti pada metode klasik. Laporan ini merangkum lima jurnal/artikel ilmiah rujukan tentang CNN dan Object Recognition, mendiskusikan cara kerja algoritma CNN, serta melaporkan hasil eksplorasi awal terhadap dataset CIFAR-10 yang akan digunakan pada tahap penelitian berikutnya.

2. Studi Literatur

2.1 Ringkasan Jurnal / Artikel Ilmiah

Berikut ringkasan lima artikel ilmiah rujukan utama dalam perkembangan CNN dan Object Recognition, dipilih karena masing-masing merepresentasikan tonggak (milestone) penting yang saling melengkapi satu sama lain.

1. ImageNet Classification with Deep Convolutional Neural Networks (AlexNet)
Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). Advances in Neural Information Processing Systems (NeurIPS).

Artikel ini memperkenalkan AlexNet, salah satu CNN besar pertama yang berhasil melatih 1,2 juta gambar berresolusi tinggi ke dalam 1000 kelas pada kompetisi ImageNet LSVRC-2010/2012. Arsitekturnya terdiri dari lima convolutional layer (sebagian diikuti max-pooling) dan beberapa fully-connected layer dengan softmax di akhir. Kontribusi pentingnya adalah pemanfaatan GPU untuk mempercepat pelatihan, penggunaan fungsi aktivasi non-saturating (ReLU) agar konvergensi lebih cepat, serta teknik regularisasi dropout untuk mengurangi overfitting pada layer fully-connected. Hasilnya jauh melampaui metode state-of-the-art sebelumnya dan menjadi titik balik yang memicu ledakan riset deep learning di bidang computer vision.

2. Very Deep Convolutional Networks for Large-Scale Image Recognition (VGGNet)
Simonyan, K., & Zisserman, A. (2014). arXiv preprint / ICLR.

Penelitian ini mengkaji pengaruh kedalaman (depth) jaringan CNN terhadap akurasi klasifikasi gambar berskala besar. Berbeda dari pendekatan sebelumnya yang memakai filter konvolusi besar, VGGNet secara konsisten menggunakan filter konvolusi kecil berukuran 3x3 namun menumpuknya hingga 16-19 lapisan bobot (dikenal sebagai VGG-16 dan VGG-19). Pendekatan ini terbukti meningkatkan akurasi secara signifikan dan berhasil meraih peringkat pertama serta kedua pada ImageNet Challenge 2014 (kategori localisation dan classification). Artikel ini menegaskan prinsip penting dalam desain CNN: menambah kedalaman jaringan dengan filter kecil dan seragam lebih efektif dibanding memperbesar ukuran filter.

3. Deep Residual Learning for Image Recognition (ResNet)
He, K., Zhang, X., Ren, S., & Sun, J. (2016). Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR).

Artikel ini mengatasi masalah degradasi akurasi yang muncul ketika CNN dibuat semakin dalam — bukan karena overfitting, melainkan karena jaringan yang sangat dalam justru semakin sulit dioptimasi. Solusinya adalah residual learning: setiap blok jaringan tidak lagi mempelajari fungsi pemetaan langsung, melainkan mempelajari residual (selisih) terhadap input sebelumnya, direalisasikan lewat koneksi pintasan (skip/shortcut connection). Dengan pendekatan ini, ResNet berhasil melatih jaringan hingga 152 lapisan (bahkan bereksperimen hingga 1000 lapisan pada CIFAR-10) dan meraih juara pertama ILSVRC 2015, sekaligus membuktikan bahwa jaringan yang jauh lebih dalam dapat dilatih secara stabil tanpa degradasi performa.

4. You Only Look Once: Unified, Real-Time Object Detection (YOLO)

Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR).

Berbeda dari CNN klasifikasi biasa, artikel ini membahas deteksi objek (object detection) — menentukan lokasi (bounding box) sekaligus kelas objek dalam gambar. YOLO mengubah cara pandang object detection dari proses bertahap (mengusulkan region lalu mengklasifikasikannya) menjadi satu masalah regresi tunggal: satu jaringan neural memprediksi bounding box dan probabilitas kelas langsung dari keseluruhan gambar dalam sekali proses (single-pass). Pendekatan end-to-end ini membuat YOLO sangat cepat (hingga 45 frame per detik pada versi dasarnya, dan 155 fps pada varian Fast YOLO), sehingga cocok untuk aplikasi deteksi objek real-time seperti pada kendaraan otonom dan sistem pengawasan.

5. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks

Ren, S., He, K., Girshick, R., & Sun, J. (2015). Advances in Neural Information Processing Systems (NeurIPS).

Artikel ini menyempurnakan keluarga arsitektur R-CNN (Region-based CNN) untuk object detection. Sebelumnya, proses pengusulan wilayah (region proposal) menjadi bottleneck kecepatan karena dihitung terpisah dari jaringan deteksi. Faster R-CNN memperkenalkan Region Proposal Network (RPN) — jaringan konvolusi yang berbagi fitur dengan jaringan deteksi (Fast R-CNN) sehingga proses pengusulan wilayah menjadi hampir tanpa biaya komputasi tambahan. Hasilnya adalah sistem deteksi objek yang jauh lebih cepat namun tetap akurat, mencapai performa state-of-the-art pada dataset PASCAL VOC pada masanya, dan menjadi dasar bagi banyak arsitektur object detection modern berikutnya.

2.2 Diskusi Algoritma CNN dan Cara Kerjanya

Kelima artikel di atas menunjukkan variasi arsitektur (AlexNet, VGGNet, ResNet) maupun variasi tugas (klasifikasi vs. deteksi objek pada YOLO dan Faster R-CNN), namun seluruhnya dibangun di atas komponen dasar CNN yang sama. Secara umum, alur kerja CNN terdiri dari lapisan-lapisan berikut:

1. Convolutional Layer — lapisan ini menerapkan sejumlah filter (kernel) kecil yang bergeser (sliding) ke seluruh area gambar untuk mengekstraksi fitur lokal seperti tepi, sudut, dan tekstur. Setiap filter menghasilkan satu feature map. Pada lapisan-lapisan awal, fitur yang dipelajari cenderung sederhana (tepi, warna); semakin dalam lapisannya, fitur yang terbentuk semakin abstrak (bagian objek, hingga objek utuh).

2. Fungsi Aktivasi (ReLU) — setelah konvolusi, fungsi aktivasi non-linear seperti ReLU (Rectified Linear Unit) diterapkan agar jaringan mampu mempelajari pola yang kompleks (non-linear), bukan sekadar kombinasi linear dari input. ReLU juga membantu mempercepat proses pelatihan dibanding fungsi aktivasi lama seperti sigmoid/tanh, sebagaimana ditekankan pada studi AlexNet.

3. Pooling Layer (Subsampling) — lapisan ini mengurangi ukuran spasial feature map (misalnya lewat max-pooling, mengambil nilai maksimum pada suatu area kecil), sehingga mengurangi jumlah parameter dan komputasi, sekaligus membuat fitur yang dipelajari lebih tahan terhadap pergeseran atau distorsi kecil pada gambar.

4. Fully-Connected Layer — setelah beberapa kali proses konvolusi dan pooling, feature map yang tersisa diratakan (flatten) lalu dihubungkan ke satu atau beberapa lapisan neuron yang saling terhubung penuh, berfungsi menggabungkan seluruh fitur yang telah diekstraksi untuk pengambilan keputusan akhir.

5. Lapisan Output (Softmax / Regressor) — untuk tugas klasifikasi, lapisan terakhir biasanya berupa fungsi softmax yang mengubah nilai keluaran menjadi probabilitas untuk setiap kelas. Untuk tugas deteksi objek seperti pada YOLO, lapisan output berbentuk regresi yang langsung memprediksi koordinat bounding box beserta skor kepercayaan kelasnya.

6. Proses Pelatihan (Training) — seluruh bobot pada filter konvolusi dan lapisan fully-connected dipelajari melalui proses backpropagation dan optimisasi berbasis gradient descent (atau variannya seperti SGD dengan

momentum), dengan meminimalkan fungsi loss (misalnya cross-entropy untuk klasifikasi). Teknik tambahan seperti dropout (AlexNet) dan koneksi residual (ResNet) dipakai untuk menjaga jaringan yang besar/dalam tetap dapat dilatih secara stabil dan tidak overfitting.

Perkembangan dari AlexNet ke VGGNet dan ResNet menunjukkan tren umum: CNN menjadi semakin dalam untuk menangkap fitur yang lebih kaya, dengan inovasi arsitektur (filter kecil pada VGGNet, koneksi residual pada ResNet) yang membuat jaringan dalam tersebut tetap bisa dilatih secara efektif. Sementara itu, YOLO dan Faster R-CNN menunjukkan bagaimana komponen dasar CNN yang sama dapat diperluas dari sekadar klasifikasi gambar menjadi deteksi objek (lokasi + kelas) secara efisien dan bahkan real-time.

3. Eksplorasi Dataset

3.1 Pemilihan Dataset

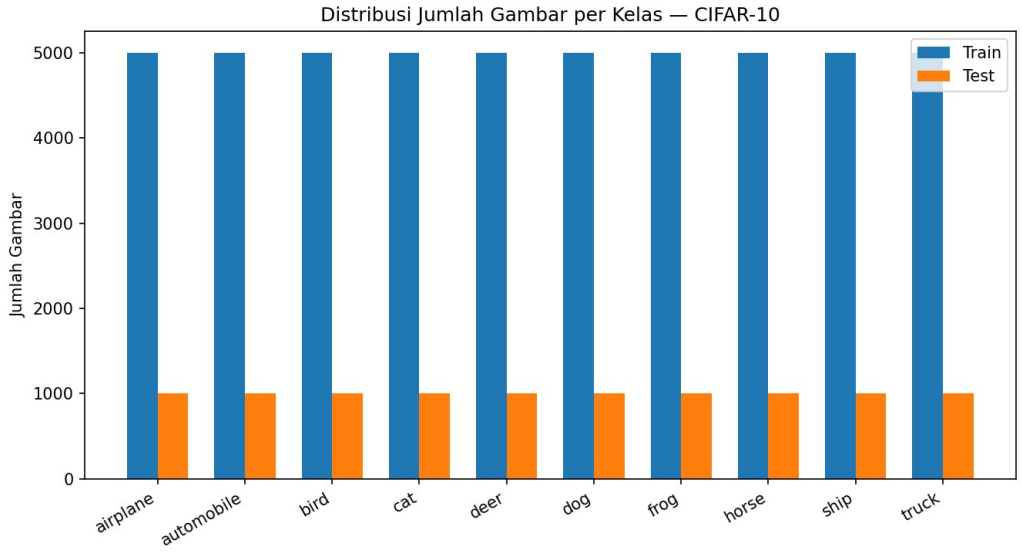
Dataset yang dipilih untuk penelitian ini adalah CIFAR-10, dataset standar untuk tugas image classification / object recognition. Dataset diunduh dalam bentuk gambar PNG asli (bukan format biner khusus), sehingga proses visualisasi dan eksplorasi dapat dilakukan langsung terhadap file gambar per kelas. Sumbernya adalah dataset resmi CIFAR-10 yang disusun oleh Alex Krizhevsky (University of Toronto), yang telah dikonversi ke format folder gambar per kelas (train/ dan test/) oleh komunitas open-source agar mudah dieksplorasi tanpa proses unpickle biner.

3.2 Karakteristik Dataset

Properti	**Nilai**
Jumlah kelas	10 kelas: airplane, automobile, bird, cat, deer, dog, frog, horse, ship, truck
Jumlah gambar total	60.000 (50.000 data latih / train + 10.000 data uji / test)
Jumlah per kelas (train)	5.000 gambar / kelas (seimbang sempurna)
Jumlah per kelas (test)	1.000 gambar / kelas (seimbang sempurna)
Ukuran gambar	32 x 32 piksel (resolusi rendah, khas dataset benchmark CNN)
Mode warna	RGB (3 channel)
Format file	PNG
Distribusi kelas	Merata / balanced — tidak ada class imbalance

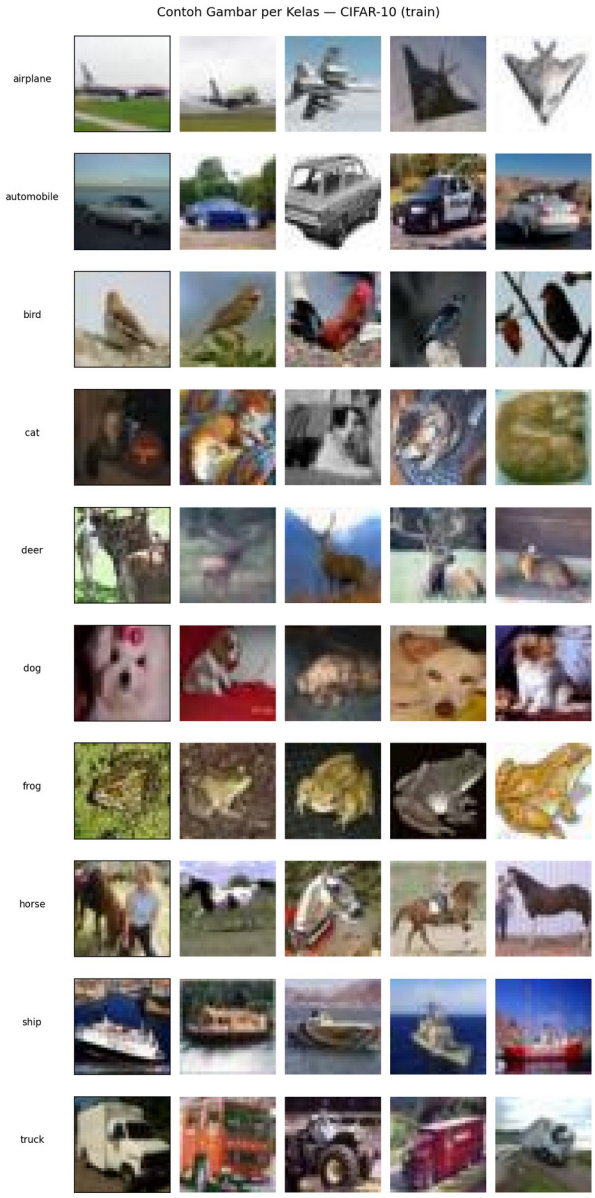
3.3 Visualisasi Distribusi Kelas

Grafik berikut membandingkan jumlah gambar per kelas pada data train dan test. Terlihat bahwa distribusi benar-benar seimbang di seluruh 10 kelas, sehingga tidak diperlukan teknik penanganan class imbalance (seperti oversampling/undersampling) sebelum pelatihan model CNN.



3.4 Visualisasi Contoh Gambar per Kelas

Berikut 5 sampel acak dari setiap kelas untuk memberi gambaran variasi visual dalam dataset (sudut pandang, warna latar, ukuran objek relatif terhadap frame, dan tingkat keburaman akibat resolusi rendah).



3.5 Catatan Eksplorasi & Karakteristik Tambahan

- Resolusi rendah (32x32) membuat beberapa objek sulit dikenali bahkan secara visual oleh manusia, terutama pada kelas cat, dog, dan deer yang bentuknya cenderung mirip pada resolusi kecil.
- Variasi latar belakang cukup tinggi — tidak semua gambar memiliki objek yang terpusat/menempati sebagian besar frame, ini relevan dengan pembahasan Bagian 2.2 tentang pentingnya convolutional layer dalam mengekstrak fitur lokal, bukan hanya bergantung pada posisi objek.
- Karena distribusi kelas seimbang, metrik akurasi (accuracy) cukup representatif untuk evaluasi model nanti, tanpa perlu bergantung pada metrik khusus imbalance seperti F1-score per kelas.
- Dataset ini umum dipakai sebagai benchmark awal karena ukurannya kecil (total ±180MB dalam bentuk gambar), sehingga cocok untuk eksperimen CNN sederhana (mengacu pada arsitektur seperti AlexNet/VGGNet skala kecil) dengan waktu training yang relatif singkat.

4. Kesimpulan

Studi literatur terhadap lima artikel rujukan (AlexNet, VGGNet, ResNet, YOLO, dan Faster R-CNN) menunjukkan evolusi CNN dari arsitektur dasar untuk klasifikasi gambar hingga arsitektur khusus untuk deteksi objek real-time, dengan inovasi berkelanjutan pada kedalaman jaringan, efisiensi komputasi, dan stabilitas pelatihan. Dataset CIFAR-10 yang dipilih untuk tahap eksplorasi memiliki karakteristik yang sesuai untuk eksperimen awal CNN: jumlah kelas dan gambar yang jelas, distribusi kelas seimbang, serta ukuran dataset yang ringan namun tetap representatif untuk tugas object recognition. Kombinasi pemahaman teori (studi literatur) dan pemahaman data (eksplorasi dataset) ini menjadi dasar bagi tahap penelitian berikutnya, yaitu perancangan dan pelatihan model CNN untuk pengenalan objek.

Daftar Pustaka

Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet Classification with Deep Convolutional Neural Networks. Advances in Neural Information Processing Systems (NeurIPS), 25.

Simonyan, K., & Zisserman, A. (2014). Very Deep Convolutional Networks for Large-Scale Image Recognition. arXiv preprint arXiv:1409.1556.

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 770–778.

Redmon, J., Divvala, S., Girshick, R., & Farhadi, A. (2016). You Only Look Once: Unified, Real-Time Object Detection. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 779–788.

Ren, S., He, K., Girshick, R., & Sun, J. (2015). Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. Advances in Neural Information Processing Systems (NeurIPS), 28.

Krizhevsky, A. (2009). Learning Multiple Layers of Features from Tiny Images (CIFAR-10 dataset). University of Toronto.